

ホモロジーの永続性を利用した異常検知

黒木 裕鷹

2018 年 4 月 27 日

1 はじめに

現在、世界の様々な工場では産業用ロボットが用いられている。そのような工場では、重量物の運搬を必要としたり、霧散している粉塵を吸い込んだりする危険性など、人間には負担の大きい作業の割合が多い。産業用ロボットはこのような安全性の問題を解決するだけでなく、経済性や効率性においてもメリットがある。しかし同時にロボットには故障のリスクがあり、ただひとつのロボットの故障が生産ライン全体に影響を及ぼし得る。故障を未然に回避するためにはメンテナンスなどの保守作業を行うことが重要であるが、メンテナンスや部品交換にも費用や時間などコストがかかるため、適切なタイミングで行われることが望ましい。

自動車メーカーの M では、生産ラインで使用するアームロボットの故障を未然に防ぐため、その減速機の交換を経験に基づくタイミングで行っている。交換のタイミングが遅すぎれば故障を招くが、早すぎても交換に時間がかかる分パフォーマンスが低下することとなる。本調査では、ロボットアームをモニタリングした振動のセンサーデータを用い、減速機交換前後のデータに明確な違いがあるかどうかを調査した。ロボットの故障により生産ラインを止めることはあってはならないため、故障直前のデータは得ることが出来ないことに留意しなければならず、教師無し学習によるクラスタリングを行うことを目的とした。

M より提供されたデータは一つのロボットアームにつき、減速機交換前後それぞれで 5 秒間の計測を 10 回行った 1 次元の振動データである。ロボットアームはそれぞれ挙動が異なるため、その主要な振動はアームごとに異なっている。また、各アームの行動 1 セットは 5 秒間ではないため、各計測ごとにより行動セットの中の計測する部分が異なっている。

クラスタ分析では、クラスタリングされる対象間の類似度もしくは非類似度が必要である。時系列を対象としたクラスタリングにおいて、最も広く使用されている尺度はユークリッド距離、Dynamic Time Warping(DTW), CORT などである。DTW は 2 つ時系列データの時刻を t_1, t_2 とすると、 t_1, t_2 全ての組の誤差を計算し、それらの合計が最小になるような経路を求めるアルゴリズムである。DTW により計測開始時点が異なる問題は多少解決されるが、振動の主な挙動はアームによって異なるため、減速機交換前後の差異はクラスタリングの結果に表れない。また、未知音源分離で用いられる独立成分分析(ICA)は主要な振動と微細な振動を分けることを可能にするかもしれないが、同時点の複数観測を必要とするため本データには適用することはできない。つまり時系列の同時性を利用することなく、かつアームごとに異なる主要な振動に影響されない特徴量によって教師無し学習を行うことが課題である。

本調査では、以上のような課題を解決するため、データの位相的な特徴に注目した。近年着目されている Topological Data Analysis(TDA)は複雑なデータを扱う上で強力であり、パーシステント・ホモロジーをはじめとするその手法はデータの位相的特徴を抽出し、新しい知見を与える。また TDA の分野で広く行われているように、時

時間遅れ座標を用いて時系列を多次元に埋め込むことで位相的特徴を抽出する足掛かりとした。時間遅れ座標による埋め込みはダイナミカルシステムの分野で、状態空間の復元を目的に広く用いられている。

本レポートの構成は次のようである。まず2節では本調査で使用したTDAの手法やクラスタリング手法について述べ、3節では実際のデータ解析とその結果を示す。4節では考察を行うと共に今後の展望について触れる。

2 TDA とクラスタリング

TDAにおいて主要な技術となるのが Persistent Homology [1] である。

3 データ解析

本調査では、自動車メーカー M の産業用ロボットアームの振動データを扱う。15種類のロボットアームに対し、減速機を交換する前と交換した後をそれぞれ10回モニタリングした合計300系列のデータである。計測の基本単位は100ミリ秒であり、計測の長さは5秒間である。ロボットアーム15種類の減速機交換前後のデータのそれぞれ10回分の観測をつなぎ合わせ、以下の図1に示した。このように、いずれのロボットアームにおいてもその時系列は明らか非線形構造を持つと同時に交換前後の系列は似通っており、アームごとの挙動が主要な振動として現れていることがわかる。減速機交換前後の特徴を目視で判断することは出来ない。さらに交換前後で計測開始時間が異なるものもあり、単純な比較が難しいことがわかる。10回の観測をつなぎ合わせたが、系列は概ね周期的になっている。しかし一部に周期的でなかったり、交換前後で明らかに異なった振動をしている系列が見て取れる。

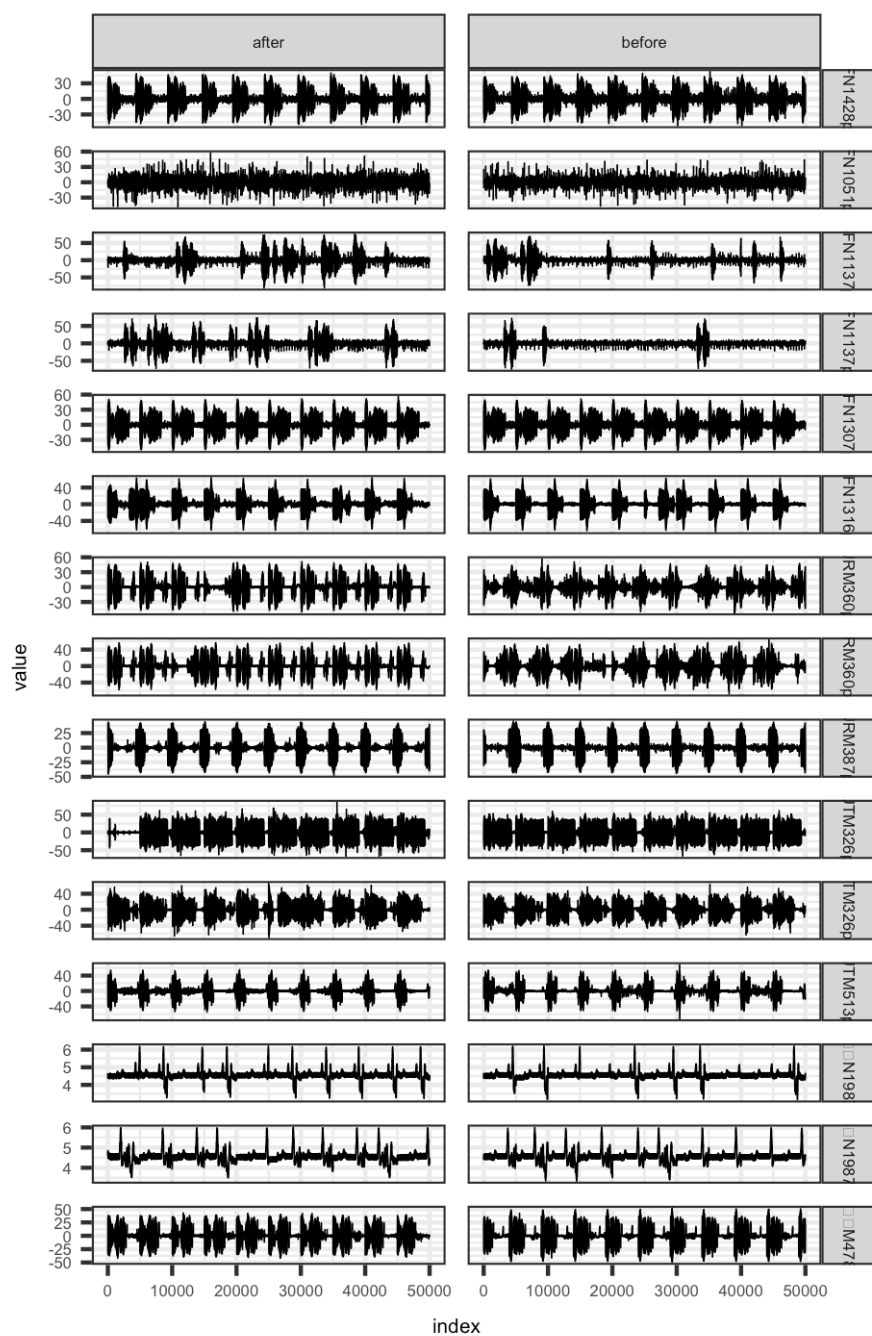


図 1: センサーデータの時系列プロット

4 Persistent Diagram とその要約

位相幾何学的データ分析の中でもキーとなるのが, Persistent Homology(PH) である. 本節では, 例として次の図 2 の点群を考えることとする.




図 2: Point Cloud example

4.1 persistence diagram

大きな情報を持つ PH の直接的な表現として, Persistent Diagram(PD) と呼ばれる方法が主流である. 横軸にホモロジーが生まれる時の半径 $Birth(r)$ をとり, 縦軸にホモロジーが消滅する時の半径 $Deaty(r)$ を取った散布図である. 図 3 に図 2 の PD を示した. そのため, パーシステント・ホモロジーを要約する手法が盛んに提案されてきた.

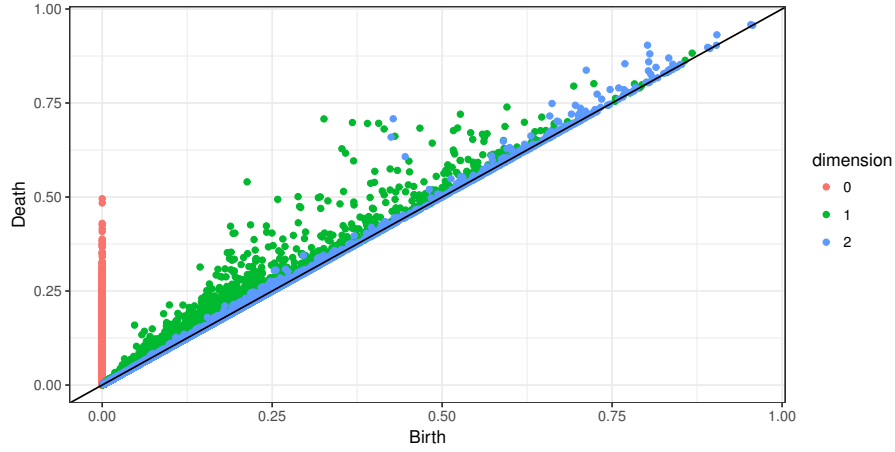


図 3: Persistent Diagram example

PD は散布図であるため，そこから明確な情報を読み取ることは非常に難しい．そのため，PD を要約する手法が盛んに考えられてきた．

4.2 maximum persistence

PD の要約としてもっとも単純なものが maximum persistence である．maximum persistence は i 番目の点群の persistence diagram D_i の n 次元ホモロジーに対して以下で計算され，1 つの点群に由来するホモロジーに対し最大の永続性を記述する．

$$\max\text{Pers}(D_i) = \max_{(birth, death) \in D_i} (Death(r) - Birth(r))$$

4.3 persistence landscape

ノイズを含んだ実データでは，生まれてすぐに死ぬホモロジーが多数存在することになる．つまり，より強い永続性を持ったものに着目することが重要であるとかんがえられる．そこで，大きな永続性を持つホモロジーのみに着目する目的で persistence landscape (PL) がしばしば用いられる．PL は区分的な線形関数であり， p 番目のホモロジーで $Birth(r) = b, Death(r) = d$ であったとすると

$$\Lambda_p(t) = \begin{cases} t - b, & b < t < (b + d)/2 \\ d - t, & (b + d)/2 < t < d \\ 0 & \text{otherwise} \end{cases}$$

を考え，PL は

$$F(t) = \sup(\Lambda_p(t))$$

で与えられる．図 3 PL を図 4 に示した．




図 4: Persistence Landscape example

4.4 persistence barcode

ホモロジー p が生まれてから死ぬまでを実線で表して並べたものを persistent barcode という。ただし、 p の決め方に恣意性が生まれないよう注意する必要がある。その例を図 5 に示した。左から順に 0 次元のホモロジー，1 次元のホモロジー，2 次元のホモロジーの persistence barcode である。




図 5: Persistence Barcode example

5 時系列データに対する位相幾何学的アプローチ

本調査で扱う時系列データは1次元のデータであるため、前節で述べた TDA のメソッドを適用するためには多次元の点群を作成する必要がある。1次元時系列を多次元の点群に加工する手段として、時間遅れ座標を用いた埋め込みが知られている。埋め込みは、非線形ダイナミカルシステムの分野でアトラクタを再構成するために利用される。埋め込む次元 m の決定にはターケンスの埋め込み定理や FFN(False Nearest Neighbors) 利用が行われている。また、時間遅れ単位 d は大きすぎても小さすぎてもいけないこと、明らかな周期の整数倍になってはいけないことが報告されている。

しかし、埋め込み次元 m のを増やすと PH の計算量は指数的に増加することになる。そのため、十分多次元に埋め込んだのち、主成分分析などにより3次元に圧縮することが提案されている [2]。

6 Persistent Diagram の比較

6.1 Wasserstein distance

Wasserstein distance は、一つの変数がもう一方の（確率論的あるいは決定論的に）非一様な小さい摂動によって得られるような、二つの変数 X と Y の確率分布を比較する際に自然に用いられる。[3] は PD の空間上に Wasserstein distance で距離を定義し、またその上の確率測度を調べている。

6.2 bottleneck distance

[4] によって提案された bottleneck distance も Wasserstein distance と同様、二つの PD の類似度を測る指標である。2つの PD（と対角線上の全ての点）が完全に一致するまでの最短距離である。図 6 にその例を示した




図 6: bottleneck example

7 結果

8 考察

参考文献

- [1] Edelsbrunner, Letscher, and Zomorodian. Topological persistence and simplification. *Discrete & Computational Geometry*, Vol. 28, No. 4, pp. 511–533, Nov 2002.
- [2] Patrick Truong. An exploration of topological properties of high-frequency one-dimensional financial time series data using tda. Master’s thesis, KTH, Mathematical Statistics, 2017.
- [3] Katharine Turner, Yuriy Mileyko, Sayan Mukherjee, and John Harer. Fréchet means for distributions of persistence diagrams. *Discrete & Computational Geometry*, Vol. 52, No. 1, pp. 44–70, Jul 2014.
- [4] Peter Bubenik. Statistical topological data analysis using persistence landscapes. *Journal of Machine Learning Research*, Vol. 16, pp. 77–102, 2015.